

Análisis Predictivo de Abandono de Clientes

Aplicación de Machine Learning en el marco de la Industria 4.0

Alumno: Santiago Díaz

Curso: Data Science I — Fundamentos para la Ciencia de Datos

Junio 2026

1. Contexto del Problema	3
Impacto económico	3
Conexión con Industria 4.0	3
Objetivo del proyecto	3
2. Descripción del Dataset	3
3. Hipótesis de trabajo	4
4. Carga y Exploración de Datos	5
4.1 Inspección General	5
4.2 Valores Nulos y Variable Objetivo	5
4.3 Tratamiento de Valores Faltantes	6
5. Análisis Exploratorio de Datos (EDA)	6
5.1 Distribución de la Variable Objetivo	6
5.2 Distribución de Variables Numéricas	7
5.3 Churn por Variables Categóricas	8
5.4 Matriz de Correlación	9
5.5 Feature Engineering — cargo_relativo	9
6. Preprocesamiento de Datos	10
6.1 División Train/Test	10
6.2 Pipeline de Preprocesamiento	10
7. Modelado	11
7.1 Entrenamiento de Modelos Baseline	11
7.2 Optimización de Hiperparámetros (GridSearchCV)	12
7.3 Evaluación de Modelos	13
7.3.1 Classification Report — Análisis por Clase	13
7.4 Importancia de Variables	14
8. Conclusiones e Insights	15
9. Sección Teórica	16
10. Referencias bibliográficas y fuentes de datos	18

1. Contexto del Problema

En un mercado donde cambiar de proveedor toma minutos, retener clientes se convirtió en una ventaja competitiva tan importante como conseguirlos.

A la pérdida de clientes se la conoce como *Churn* y detectarla a tiempo, antes de que ocurra, es precisamente una de las capacidades que la ciencia de datos permite desarrollar hoy.

Impacto económico

Adquirir un cliente nuevo puede costar entre 5 y 25 veces más que retener uno existente, con variaciones según el tipo industria y modelo de negocio (Churnkey, 2026). Sin embargo, la pérdida de clientes no implica únicamente una reducción de ingresos inmediatos. También supone la pérdida del valor acumulado de toda la relación comercial, conocido como **Customer Lifetime Value (CLV)**. Identificar con anticipación a los clientes en riesgo de abandono adquiere entonces una relevancia estratégica concreta.

Conexión con Industria 4.0

Las herramientas que hoy ofrece la ciencia de datos -como el análisis exploratorio, machine learning y los pipelines reproducibles- permiten convertir datos históricos de clientes en decisiones estratégicas concretas. Eso es, en esencia, lo que propone la Industria 4.0: transformar datos en conocimiento accionable para la toma de decisiones.

Objetivo del proyecto

Construir y evaluar un modelo de machine learning capaz de identificar clientes con alta probabilidad de abandono a partir de variables demográficas, contractuales y de consumo. El objetivo es generar una herramienta que permita anticipar acciones de retención basadas en evidencia y contribuir a la toma de decisiones estratégicas.

2. Descripción del Dataset

Fuente: IBM Sample Dataset - Telco Customer Churn - Kaggle

 <https://www.kaggle.com/datasets/blatchar/telco-customer-churn>

El conjunto de datos reúne información demográfica, contractual y de consumo correspondiente a clientes de una empresa proveedora de servicios de telecomunicaciones. Su objetivo es analizar los factores asociados al abandono del servicio y construir modelos capaces de anticipar dicho comportamiento.

Características generales:

- **Registros:** 7.043 clientes
- **Variables:** 21 columnas
- **Variable objetivo:** Churn (Yes/No) - indica si el cliente abandonó el servicio el último mes.

Tipos de variables:

- **Demográficas:** género, ciudadano mayor, pareja, dependientes.
- **Contractuales:** tipo de contrato, método de pago, facturación electrónica.
- **De consumo y uso del servicio:** antigüedad, cargos mensuales, cargos totales, servicios contratados (internet, seguridad, soporte, streaming).

Calidad de datos

Durante la inspección inicial se identificaron **11 valores faltantes** en la variable *TotalCharges*. El análisis mostró que dichos registros correspondían a clientes con antigüedad igual a cero meses, por lo que su ausencia resultó consistente con la lógica del negocio y no respondió a errores aleatorios de captura. El resto de las variables no presentó valores nulos.

Asimismo, se identificó un **desbalance moderado** en la variable objetivo: **73.5%** No Churn vs **26.5%** Churn. Este desequilibrio resulta relevante para el modelado, ya que en presencia de clases desbalanceadas, métricas como la accuracy pueden ofrecer una visión incompleta del desempeño del modelo. Por ello se priorizaron métricas adecuadas para conjuntos desbalanceados durante la evaluación del modelo.

3. Hipótesis de trabajo

Antes de iniciar el análisis exploratorio, se formularon las siguientes hipótesis sobre los factores asociados al churn:

H1 — *Los clientes con menor antigüedad tienen mayor probabilidad de abandonar el servicio, dado que aún no han consolidado una relación de fidelidad con la empresa.*

H2 — *El tipo de contrato es un predictor relevante: los clientes con contratos mes a mes presentan mayor riesgo de churn que aquellos con contratos de uno o dos años.*

H3 — *Los clientes con cargos mensuales más elevados muestran mayor tendencia al abandono, posiblemente asociado a una percepción de menor valor del servicio.*

💡 *Estas hipótesis orientan el análisis inicial y serán contrastadas mediante la exploración de los datos y la evaluación de los modelos predictivos construidos.*

4. Carga y Exploración de Datos

El dataset fue cargado desde Google Drive utilizando la librería pandas. El archivo contiene 7.043 registros y 21 columnas, con una combinación de variables numéricas, enteras y categóricas.

4.1 Inspección General


La inspección inicial reveló que el dataset contiene 18 variables categóricas (object), 2 enteras (int64) y 1 numérica decimal (float64). Se detectó además que la variable *TotalCharges* requirió corrección de tipo de dato — detallada en la sección 4.3.

La antigüedad de los clientes varía entre **0 y 72 meses**, con un promedio de **32 meses** y cargos mensuales promedio de **\$64.76**.

4.2 Valores Nulos y Variable Objetivo

La inspección inicial confirmó la ausencia de valores nulos declarados. Sin embargo, la conversión de *TotalCharges* a formato numérico reveló **11 valores faltantes** enmascarados como espacios en blanco — tratados en la sección 4.3.

Se utilizó la librería **missingno** para visualizar el patrón de valores faltantes en el dataset. El gráfico confirma que el dataset es de alta calidad: la única variable con ausencias es *TotalCharges*, con un patrón estructural no aleatorio. Todos los registros afectados corresponden a clientes con antigüedad igual a cero meses, consistente con la lógica del negocio.



La variable objetivo *Churn* presenta un desbalance moderado (**73.46%** No Churn / **26.54%** Churn), lo que orientó la selección de métricas hacia **ROC-AUC** y **F1-score**.

4.3 Tratamiento de Valores Faltantes

Los **11 registros** identificados en la sección anterior fueron imputados con el valor **0**, decisión coherente con el contexto del negocio: clientes con **antigüedad igual a cero meses** aún no habían generado cargos acumulados.

```
=====
✍ CORRECCIÓN DE TOTALCHARGES
=====
Valores nulos encontrados en TotalCharges: 11

Filas con TotalCharges nulo:
  customerID  tenure  MonthlyCharges  TotalCharges
488  4472-LVYGI      0           52.55           NaN
753  3115-CZMZD      0           20.25           NaN
936  5709-LVOEQ      0           80.85           NaN
1082 4367-NUYAO      0           25.75           NaN
1340 1371-DWPAZ      0           56.05           NaN
3331 7644-OMVMY      0           19.85           NaN
3826 3213-VVOLG      0           25.35           NaN
4380 2520-SGTTA      0           20.00           NaN
5218 2923-ARZLG      0           19.70           NaN
6670 4075-WKNIU      0           73.35           NaN
6754 2775-SEFEE      0           61.90           NaN
```

A partir de este hallazgo, se procedió a imputar los valores faltantes con 0.

```
=====
✍ IMPUTACIÓN DE TOTALCHARGES
=====
Nulos restantes en TotalCharges: 0
Tipo de dato corregido: float64

✅ TotalCharges corregido correctamente
```


5. Análisis Exploratorio de Datos (EDA)

En esta sección se explora la distribución de las variables, la relación entre *features* y la variable objetivo *Churn*, y se identifican patrones relevantes para el modelado.

5.1 Distribución de la Variable Objetivo

Se analizó la distribución de la variable objetivo *Churn* para evaluar el balance entre clientes que abandonaron el servicio y los que permanecieron.


Variable Objetivo: Churn



El dataset presenta un desbalance moderado: **73.5%** de los clientes no realizaron churn frente a un **26.5%** que sí abandonó el servicio. Dado que la clase minoritaria es precisamente la de mayor interés predictivo, este desequilibrio condicionó tanto la estrategia de modelado como la selección de métricas de evaluación.

5.2 Distribución de Variables Numéricas

Se analizó el comportamiento de *tenure*, *MonthlyCharges* y *TotalCharges* en función de la variable objetivo, con el fin de identificar diferencias distributivas entre clientes que realizaron churn y los que permanecieron.




Los histogramas revelan patrones claros asociados al churn:

- Los clientes con **menor antigüedad** concentran la mayor proporción de abandonos, confirmando que los primeros meses son el período de mayor riesgo.
- Los clientes con **cargos mensuales más elevados** muestran mayor tendencia al abandono, posiblemente asociado a una percepción de menor valor del servicio.

- **TotalCharges** presenta una distribución similar a *tenure* — consecuencia directa de su alta correlación (0.83), confirmada posteriormente en la matriz de correlación.

5.3 Churn por Variables Categóricas

Se analizó la distribución del churn según las principales variables categóricas para identificar segmentos de mayor riesgo.




Los gráficos revelan diferencias marcadas entre categorías:

- **Contrato:** los clientes con contrato mes a mes concentran la mayor proporción de churn — al no generar compromiso a largo plazo, representan el segmento de mayor riesgo.
- **Servicio de internet:** los clientes con fibra óptica muestran mayor tendencia al abandono, comportamiento consistente con sus cargos mensuales más elevados.
- **Método de pago:** el cheque electrónico se asocia con mayor abandono respecto al débito automático, lo que podría reflejar menor vínculo con la empresa.
- **Género:** no muestra diferencias significativas entre clases y no será considerado como predictor relevante en el modelo.

5.4 Matriz de Correlación

Se calculó la matriz de correlación entre las variables numéricas del dataset para identificar relaciones lineales y posibles redundancias entre predictores.




La matriz revela tres relaciones relevantes para el modelado:

- **tenure y TotalCharges (0.83):** correlación muy alta — a mayor antigüedad, mayores cargos acumulados. Ambas variables capturan información similar, lo que fue considerado durante el preprocesamiento.
- **Churn y tenure (-0.35):** correlación negativa — a mayor antigüedad, menor probabilidad de churn. Confirma lo observado en la distribución de variables numéricas y respalda la H1.
- **Churn y MonthlyCharges (0.19):** correlación positiva leve — cargos más altos se asocian con mayor churn, en línea con la H3.

5.5 Feature Engineering — cargo_relativo

A partir del análisis exploratorio se construyó una nueva variable: $\text{cargo_relativo} = \text{MonthlyCharges} / (\text{tenure} + 1)$. Esta *feature* captura el costo mensual normalizado por el tiempo de permanencia, con la hipótesis de que un cargo elevado durante los primeros meses representa mayor riesgo que el mismo cargo en un cliente consolidado.



La distribución por clase confirma que los clientes con churn presentan valores de `carga_relativo` más altos, y la correlación con la variable objetivo es superior a la de `MonthlyCharges` aislado. La variable fue incorporada al pipeline de preprocesamiento como feature numérica adicional.

6. Preprocesamiento de Datos

Como parte del **feature engineering** previo al modelado, se realizaron las siguientes transformaciones sobre el dataset original:

- Conversión de `TotalCharges` a tipo numérico.
- Binarización de la variable objetivo `Churn` (Yes=1, No=0).
- Eliminación de `customerID` por no aportar capacidad predictiva.
- Identificación y separación de variables numéricas y categóricas para el pipeline.

Antes de entrenar el modelo, los datos fueron transformados y preparados siguiendo un flujo estructurado. Un criterio fundamental durante todo este proceso fue evitar el **data leakage** — garantizando que el modelo nunca acceda a información del conjunto de prueba durante el entrenamiento. Para ello se utilizó un **Pipeline de scikit-learn**.

6.1 División Train/Test

El dataset fue dividido en **80%** entrenamiento (5.634 registros) y **20%** prueba (1.409 registros). Se utilizó el parámetro `stratify=y` para garantizar que ambos conjuntos mantengan la misma proporción de churn (**26.54%**), evitando que el modelo se entrene o evalúe con una distribución distinta a la real.

6.2 Pipeline de Preprocesamiento

Se construyó un Pipeline de scikit-learn con dos ramas paralelas que operan simultáneamente sobre distintos tipos de variables:

Variables numéricas (*tenure*, *MonthlyCharges*, *TotalCharges*, *SeniorCitizen*):

- Imputación con la mediana — robusta ante valores extremos.

- Escalado con *StandardScaler* — lleva todas las variables a la misma escala, necesario para modelos sensibles a la magnitud como la Regresión Logística.

Variables categóricas (15 variables de servicio y contrato):

- Imputación con el valor más frecuente.
- *OneHotEncoding* — convierte categorías en columnas numéricas binarias, manteniendo independencia entre categorías.

Todo el preprocesamiento ocurre dentro del **Pipeline**, garantizando que las transformaciones se aprendan únicamente con datos de entrenamiento y se apliquen al conjunto de prueba sin **data leakage**.

7. Modelado

Se entrenaron dos modelos de clasificación integrados dentro del **Pipeline de preprocesamiento**, garantizando reproducibilidad y ausencia de **data leakage**.

7.1 Entrenamiento de Modelos Baseline

Se entrenaron dos modelos como punto de partida:

- **Regresión Logística:** modelo base, simple e interpretable, que permite establecer una referencia de rendimiento.
- **Random Forest:** modelo no lineal capaz de capturar relaciones complejas entre variables.

La evaluación inicial arrojó los siguientes resultados:

Modelo	Accuracy	ROC-AUC	F1-Score Churn
Regresión Logística	81%	0.84	0.60
Random Forest	78%	0.82	0.55

Contra lo esperado, la **Regresión Logística** superó al **Random Forest** en esta evaluación inicial, confirmando la importancia de partir siempre de un modelo simple antes de recurrir a modelos más complejos.

7.2 Optimización de Hiperparámetros (GridSearchCV)

Ambos modelos fueron optimizados mediante **GridSearchCV** con validación cruzada estratificada de **5 folds**, utilizando **ROC-AUC** como métrica principal.

Los mejores parámetros encontrados fueron:

Regresión Logística:

C: 10

solver: liblinear

Random Forest:

max_depth: 10

min_samples_split: 5

n_estimators: 200

Mejor ROC-AUC en validación cruzada:

Regresión Logística: 0.8464

Random Forest: 0.8429

Control de overfitting – brecha CV vs Test


Modelo	ROC-AUC CV	ROC-AUC Test	Brecha
Regresión Logística	0.8464	0.84	0.006
Random Forest	0.8429	0.84	0.003

La brecha entre el rendimiento en validación cruzada y el conjunto de prueba es prácticamente nula en ambos modelos, confirmando que el pipeline de preprocesamiento cumplió su objetivo: las transformaciones se ajustaron únicamente con datos de entrenamiento y el modelo generaliza correctamente a datos no vistos.

No hay evidencia de overfitting.

7.3 Evaluación de Modelos

Se evaluaron los modelos optimizados sobre el conjunto de prueba mediante matrices de confusión y curvas ROC.



Matrices de confusión:

- Ambos modelos identifican correctamente la mayoría de los clientes que no realizan churn.
- La detección de clientes que sí abandonan resulta más desafiante, con una proporción de falsos negativos esperable dado el desbalance de clases.

Curvas ROC:

- **Regresión Logística:** AUC 0.84
- **Random Forest:** AUC 0.84
- Ambas curvas se alejan claramente de la diagonal que representa un clasificador aleatorio, indicando buen poder predictivo en ambos casos.

Ante rendimientos equivalentes, se seleccionó la **Regresión Logística** como modelo final por ser más simple, interpretable y eficiente.

7.3.1 Classification Report — Análisis por Clase


El reporte revela un patrón típico de datasets con desbalance de clases: el modelo identifica correctamente el 90% de los clientes que no realizan churn (recall 0.90), pero

detecta solo el 53% de los clientes que sí abandonan (recall 0.53). Esto significa que casi la mitad de los churners reales no son capturados por el modelo con el umbral de clasificación por defecto (0.5).

Desde el punto de vista de negocio, este resultado orienta una decisión concreta: **reducir el umbral de clasificación** (por ejemplo a 0.3 o 0.35) aumentaría el recall de Churn a costa de más falsos positivos — es decir, más campañas de retención aplicadas a clientes que no iban a irse. En este contexto, ese trade-off es favorable: el costo de una campaña de retención innecesaria es considerablemente menor que el costo de perder un cliente sin intervenir.

7.4 Importancia de Variables

Se analizó la importancia de variables del Random Forest para identificar qué factores tienen mayor influencia en la predicción del churn.



Las variables con mayor capacidad predictiva son:

- **tenure (~0.14)**: la antigüedad del cliente es el factor más determinante, en línea con la H1.
- **TotalCharges (~0.12)**: altamente correlacionado con tenure, refleja el tiempo de permanencia del cliente.
- **Contract_Month-to-month (~0.10)**: los contratos mensuales representan el mayor riesgo de churn, confirmando la H2.

- **MonthlyCharges (~0.09):** cargos elevados se asocian con mayor probabilidad de abandono, respaldando la H3.
- **OnlineSecurity_No (~0.06):** la ausencia de seguridad online se asocia con mayor tendencia al churn.

8. Conclusiones e Insights

A partir del análisis completo se obtuvieron los siguientes hallazgos:

Sobre las hipótesis de trabajo:

- **H1 confirmada:** los clientes con menor antigüedad concentran la mayor proporción de churn, siendo *tenure* la variable con mayor capacidad predictiva según el modelo.
- **H2 confirmada:** el tipo de contrato mes a mes es el segundo predictor más relevante, con una diferencia marcada respecto a contratos de uno o dos años.
- **H3 respaldada:** los clientes con cargos mensuales más elevados presentan una mayor incidencia de churn dentro del conjunto analizado.

Sobre los modelos:

- La **Regresión Logística** resultó el modelo más efectivo con **ROC-AUC** de **0.84** y Accuracy de 81%.
- El Random Forest obtuvo resultados similares (ROC-AUC 0.84) pero con mayor complejidad.
- El **GridSearchCV** permitió optimizar ambos modelos mediante búsqueda exhaustiva con validación cruzada estratificada, sin incurrir en **data leakage**.
- Ante rendimientos equivalentes, se priorizó la Regresión Logística por ser más simple, interpretable y eficiente.

Recomendación de negocio:

Una estrategia de retención efectiva debería enfocarse en clientes nuevos con contratos mensuales y cargos elevados, interviniendo con ofertas personalizadas durante los primeros meses de relación con la empresa.

El modelo desarrollado permite identificar ese segmento de riesgo con anticipación, habilitando decisiones basadas en evidencia.

Limitaciones del estudio:

- **Datos estáticos:** el dataset representa un corte temporal único. Un análisis longitudinal permitiría capturar la evolución del comportamiento del cliente.
- **Desbalance de clases:** aunque moderado, puede afectar la capacidad del modelo para detectar todos los casos de churn. Técnicas como *SMOTE* podrían mejorar el recall de la clase positiva.
- **Variables no disponibles:** factores como calidad percibida del servicio o comparativas con la competencia podrían ser predictores relevantes no presentes en el dataset.
- **Generalización:** el modelo fue entrenado con datos de una empresa específica y requeriría reentrenamiento para aplicarse en otros contextos.

9. Sección Teórica

Pregunta 1: ¿Cuál de las siguientes opciones describe mejor los nueve elementos fundamentales de Industria 4.0? **Respuesta:** opción b).

a) Solo tecnologías digitales aplicadas a manufactura

b) Integración de sistemas ciberfísicos, IoT, big data, y automatización ✓

La Industria 4.0 implica la integración de múltiples tecnologías -no el uso exclusivo de una-, tal como lo definen sus nueve pilares fundamentales documentados en literatura especializada.

c) Uso exclusivo de inteligencia artificial en fábricas

d) Aplicación de software de oficina en procesos industriales

Pregunta 2: ¿Qué ventaja principal ofrece el uso de NumPy sobre las listas tradicionales de Python en el manejo de datos? **Respuesta:** opción b).

a) Mayor facilidad para escribir código

b) Mejor rendimiento y operaciones vectorizadas ✓

NumPy ejecuta operaciones vectorizadas sobre arrays en memoria, ofreciendo mayor rendimiento que las listas nativas de Python para el procesamiento de grandes volúmenes de datos numéricos.

c) Menor consumo de memoria sin importar el tipo de dato

d) Compatibilidad con todos los formatos de archivo

Pregunta 3: *En el contexto de machine learning supervisado, ¿qué representa el conjunto de datos de entrenamiento?* **Respuesta:** opción b).

a) Datos sin etiquetas para descubrir patrones

b) Datos con etiquetas para que el modelo aprenda relaciones 

El conjunto de entrenamiento contiene registros con etiquetas conocidas que permiten al modelo establecer relaciones entre variables predictoras y el resultado esperado, base del aprendizaje supervisado.

c) Datos usados para evaluar el modelo

d) Datos generados por el modelo

10. Referencias bibliográficas y fuentes de datos

Churnkey. (2026). Customer Acquisition vs. Retention: Cost Comparison Guide.

Recuperado de

<https://churnkey.co/blog/customer-acquisition-vs-retention-cost-comparison-guide/>

IBM. (s.f.). Telco Customer Churn Dataset. Recuperado de Kaggle:

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Scikit-learn Developers. (s.f.). Scikit-learn: Machine Learning in Python - Documentation.

Recuperado de: <https://scikit-learn.org/stable/index.htm>